

Benchmark des modèles

Données et outils IA

COMPARATIF DES MODÈLES IA MISTRAL, RAGARENN ET OVH CLOUD

Référence : 2026-HP-INT-001

Comparaison des modèles mis à disposition par l'API cloud Mistral, RAGaRenn (Eskemm Numérique) et les services OVH Cloud endpoints.

MISTRAL AI

Sources : docs.mistral.ai/models/overview, juillet 2026.

LLM généralistes

Modèle	ID API -latest	Paramètres	Function calling	Usage principal
Mistral Large 3	mistral-large-latest	675B total / 41B actifs (MoE)	Oui	Tâches complexes, meilleur raisonnement brut, multimodal
Mistral Medium 3.5	mistral-medium-latest	—	Oui	Frontier multimodal, optimisé agentique + code
Mistral Small 4	mistral-small-latest	128 experts, ~6B actifs (MoE)	Oui	Hybride instruct + raisonnement + code, rapide et économique
Ministral 3 (3B/8B/14B)	ministral-3b-latest , ministral-8b-latest , etc.	3 à 14B, denses	Oui	Vision + texte, déploiement local/edge, latence minimale

Function calling confirmé via les fiches modèles officielles Mistral, qui listent “Function Calling” (/v1/chat/completions , /v1/conversations) comme fonctionnalité de la plateforme — ex. [fiche Codestral](#), cohérente avec le reste de la gamme texte-à-texte.

LLM spécialisés code

Modèle	ID API	Function calling	Usage principal
Codestral	codestral-latest	Oui	Complétion de code, FIM (fill-in-the-middle)
Codestral Embed	codestral-embed (pas de -latest)	N/A (embedding)	Embeddings sémantiques de code (recherche, RAG sur repo)

Modèle	ID API	Function calling	Usage principal
Devstral 2	devstral-latest	Oui	Agents de code autonomes, résolution de tâches d'ingénierie logicielle (frontier)

Source function calling Codestral : [fiche modèle officielle](#), section “Features” → Function Calling listé explicitement.

Embeddings, OCR, audio

Modèle	ID API	Function calling	Usage
Mistral Embed	mistral-embed	N/A (embedding)	Embeddings texte généralistes
OCR 4	via API dédiée	N/A (OCR)	OCR avec bounding boxes, structure de document
Voxtral (Small / Mini / TTS)	dédiés	N/A (audio)	Transcription audio, synthèse vocale multilingue

Modèles “Labs” (expérimentaux)

Modèle	ID API	Function calling	Usage
Leanstral 1.5	labs-leanstral-1-5-1	Non confirmé	Preuves formelles en Lean 4 – usage très niche, à exclure sauf besoin spécifique

À exclure des recommandations sauf besoin identifié : tout ce qui commence par `labs-` (expérimental, non garanti stable).

Recommandations modèles Mistral

mistral-large-latest	# tâches complexes / raisonnement lourd
mistral-medium-latest	# bon compromis qualité/coût, agentique
mistral-small-latest	# rapide, hybride raisonnement+code, usage courant
codestral-latest	# complétion/génération de code
devstral-latest	# agents de code autonomes
mistral-embed	# embeddings texte (RAG sur ton catalogue)
codestral-embed	# embeddings code (si RAG sur repo de code)

Pas de `-latest` pour les embeddings : leur nom est déjà stable et versionné manuellement par Mistral (`mistral-embed` , `codestral-embed`).

Point de vigilance

Les alias `-latest` pointent vers la version la plus récente de chaque famille et **changent sans préavis** quand Mistral sort une mise à jour (ex: Small 3 → Small 4). Bon compromis ergonomie/stabilité pour un prototype, mais à figer sur un ID daté (ex: `mistral-small-2503`) si un jour tu passes en production et veux un comportement reproductible.

RAGARENN (ESKEMM NUMÉRIQUE)

Source : appel direct à <https://ragarenn.eskemm-numerique.fr/test@audiar/api/models> , juillet 2026. Contrairement à l'API Mistral, RAGaRenn expose un catalogue **auto-hébergé et hétérogène** : plusieurs pipelines de serving (Ollama direct, préfixe `ilaas/` , chemins HuggingFace complets, quantifications) exposent souvent **le même modèle sous 3-4 noms différents**, sans convention `-latest` fiable. Le nettoyage se fait donc manuellement, alias par alias.

LLM généralistes

Famille	ID canonique recommandé	Function calling	Doublons observés	Notes
Mistral Small 3.2 (24B)	<code>mistral-small:latest</code>	Oui	<code>mistralai/Mistral-Small-3.2-24B-Instruct-2506</code> , <code>mistral-small-3.2-24b</code> , <code>mistral-small</code> , <code>small</code> , <code>ilaas/mistral-small-3.2-24b</code>	Vision + citations activées
Mistral Small 4 (119B, pipeline ilaas)	<code>ilaas/mistral-small-4-119b</code>	Oui	—	Variante plus grosse, distincte de Small 3.2 ci-dessus
Mistral NeMo	<code>mistral-nemo:latest</code>	Oui	—	Modèle plus ancien (12B)
Llama 3.3 (70B)	<code>llama-3.3-70b</code>	Oui	<code>llama-3.3</code> , <code>llama-large</code> , <code>RedHatAI/Llama-3.3-70B-Instruct-FP8-dynamic</code> (quantifié FP8), <code>ilaas/llama-3.3-70b</code>	
Llama 3.1 (8B)	<code>llama-3.1-8b</code>	Oui	<code>llama-3.1</code> , <code>llama-small</code> , <code>meta-llama/llama-3.1-8B-Instruct</code> , <code>ilaas/llama-3.1-8b</code>	
GPT-OSS (120B)	<code>gpt-oss-120b</code>	Oui	<code>gpt-oss</code> , <code>gpt</code> , <code>ilaas/gpt-oss-120b</code>	Open-weight OpenAI
DeepSeek R1 (70B)	<code>deepseek-r1:70b</code>	Instable	—	Raisonnement – accès restreint à 2 groupes ; support function calling ajouté en mai 2025 sur la version officielle R1-0528, mais rapporté comme instable et souvent absent des tags Ollama (voir source)

Famille	ID canonique recommandé	Function calling	Doublons observés	Notes
Gemma 4 (31B, dense)	gemma-4-31b	Oui	RedHatAI/gemma-4-31B-it-NVFP4 (quantifié), ilaas/gemma-4-31b	Les deux alias incluent explicitement "31b/31B" dans le nom – doublon fiable
Gemma 4 – alias ambigu	gemma-4	Inconnu	–	Pas un doublon confirmé de la ligne ci-dessus. Alias sans métadonnées (info absent), sans indication de taille. Gemma 4 existe en au moins deux tailles publiées : 31B dense et 26B-A4B (MoE, ~4B actifs) – voir gemma-4-26b-a4b sur le classement Arena . gemma-4 pourrait pointer vers l'une ou l'autre. À vérifier avant recommandations (par ex. en interrogeant le endpoint avec ce seul ID et en comparant la taille de réponse/latence)
Qwen 3.6 (35B)	ilaas/qwen-3.6-35b-instruct	Oui	–	
Phi-4 (14B)	phi4:14b-q8_0	Limité	–	Quantifié Q8 ; support natif faible, à utiliser plutôt comme moteur de raisonnement encapsulé par ta propre logique d'agent (voir source)
Lucie (7B)	ParisNeo/Lucie-7B-Instruct-v1.1:latest	Non confirmé	–	LLM souverain français (LINAGORA / OpenLLM-France) – pas de function calling documenté
Salamandra (7B)	cas/salamandra-7b-instruct:latest	Non	–	Multilingue (BSC) – une variante dédiée salamandra-7b-instruct-tools existe séparément avec function calling, mais n'est pas celle déployée ici

Famille	ID canonique recommandé	Function calling	Doublons observés	Notes
LLaVA	llava:latest	Non	–	Multimodal image + texte, pas conçu pour l'appel de fonctions structuré
Non identifié	small-til	Inconnu	–	Alias sans métadonnées (info / meta absents dans la réponse API) – ne pas recommander sans confirmation de ce qu'il pointe réellement

LLM spécialisés code

Famille	ID canonique recommandé	Function calling	Doublons observés	Notes
Codestral	codestral:latest	Oui	–	Accès restreint à un groupe
DeepSeek Coder (33B)	deepseek-coder:33b	Non confirmé	–	Accès restreint à un groupe ; version 2024, pas de support natif documenté

Sources function calling (au-delà des cas déjà confirmés côté Mistral en partie 1) : - Llama 3.x tool calling : [Llama API — Tool Calling](#), - Gemma 4 tool use : voir [Annexe — Arena](#), source citée sur les capacités Gemma 4 - Qwen3 function calling : [Qwen Docs — Function Calling](#), - Phi-4 support limité : [Microsoft Community Hub — Function Calling with Small Language Models](#) - DeepSeek R1 function calling instable : [DeepSeek API Docs — Tool Calls](#) et [issue GitHub ollama/ollama #10935](#) - Salamandra variante tools séparée : [BSC-LT/salamandra-7b-instruct-tools sur Hugging Face](#)

Embeddings

Modèle	ID	Function calling	Usage
BGE-M3	emb/bge-m3	N/A (embedding)	Embeddings multilingues
BGE Reranker v2 M3	rank/bge-reranker-v2-m3	N/A (reranking)	Reranking de résultats de recherche

Modèles exclus

- arena-model : fonctionnalité Open WebUI (vote A/B anonyme entre modèles), pas un modèle réel.
- Tous les alias en doublon listés dans la colonne “Doublons observés” une fois l’ID canonique choisi.
- codestral:latest , deepseek-coder:33b , deepseek-r1:70b : accès restreint par groupe — vérifier que le compte test@audiar a les droits avant de recommander, sinon échec silencieux à l’usage.

Recommandation modèles RAGaRenn

mistral-small:latest	# généraliste courant
llama-3.3-70b	# généraliste plus costaud
gemma-4-31b	# généraliste très efficace, bon rapport
perf/taille	
gpt-oss-120b	# alternative open-weight
codestral:latest	# code (si droits d'accès confirmés)
deepseek-r1:70b	# raisonnement (si droits d'accès confirmés)
ParisNeo/Lucie-7B-Instruct-v1.1:latest	# LLM souverain FR, cas d'usage sensibles
emb/bge-m3	# embeddings RAG
rank/bge-reranker-v2-m3	# reranking RAG

OVHCLOUD AI

Source : [catalogue OVHcloud AI Endpoints](#), juillet 2026 — 24 modèles au catalogue. Contrairement à RAGaRenn, ce catalogue est **propre par construction** : un modèle = une entrée, pas d’alias ni de doublon. Le problème ici n’est pas le nettoyage, mais l’arbitrage coût/performance (facturation au token, affichée directement dans le catalogue).

LLM généralistes

Modèle	Paramètres	Contexte	Function calling	Prix entrée/sortie (€/Mtoken)	Licence	Notes
Meta-Llama-3_3-70B-Instruct	70B	131K	Oui	0,67 / 0,67	Llama 3.3 Community	
Mistral-Nemo-Instruct-2407	12,2B	118K	Oui	0,13 / 0,13	Apache 2.0	
Mistral-7B-Instruct-v0.3	7B	127K	Oui	0,10 / 0,10	Apache 2.0	
Qwen3-32B	32,8B	32K	Oui	0,08 / 0,23	Apache 2.0	Reasoning
gpt-oss-120b	117B	131K	Oui	0,08 / 0,40	Apache 2.0	Reasoning
gpt-oss-20b	21B	131K	Oui	0,04 / 0,15	Apache 2.0	Reasoning, le plus économique de la gamme raisonnement

LLM spécialisés Code

Modèle	Paramètres	Contexte	Function calling	Prix entrée/sortie (€/Mtoken)	Licence	Notes
Qwen3-Coder-30B-A3B-Instruct	30B (MoE, 3B actifs)	256K	Oui	0,06 / 0,22	Apache 2.0	Code Assistant

Pas de Codestral ni Devstral chez OVH — seule alternative code dédiée : Qwen3-Coder.

Modèles visuels / multimodaux

Modèle	Paramètres	Contexte	Function calling	Prix entrée/sortie (€/Mtoken)	Licence	Notes
Qwen3.5-397B-A17B	397B (MoE, 17B actifs)	262K	Oui	0,60 / 3,60	Apache 2.0	Le plus gros du catalogue, reasoning + multimodal
Qwen3.6-27B	27B	262K	Oui	0,40 / 2,70	Apache 2.0	Reasoning + multimodal
Qwen2.5-VL-72B-Instruct	72B	32K	Non	0,91 / 0,91	Qwen	Multimodal, pas de reasoning ni function calling listés au catalogue
Qwen3.5-9B	9,7B	262K	Oui	0,10 / 0,15	Apache 2.0	Le plus économique des modèles visuels
Mistral-Small-3.2-24B-Instruct-2506	24B	128K	Oui	0,09 / 0,28	Apache 2.0	Équivalent du modèle vu chez RAGaRenn – ici sous son nom HF complet, sans doublon

Embeddings et modération

Modèle	Paramètres	Function calling	Prix (€/Mtoken entrée)	Licence	Usage
bge-m3	0,567B	N/A (embedding)	0,01	MIT	Embeddings multilingues (identique à RAGaRenn)
bge-multilingual-gemma2	0,567B	N/A (embedding)	0,01	Gemma	Embeddings multilingues, variante Gemma
Qwen3-Embedding-8B	7,6B	N/A (embedding)	0,10	Apache 2.0	Embeddings, plus gros modèle → meilleure qualité sémantique
Qwen3Guard-Gen-8B	8B	Non	Gratuit (bêta)	Apache 2.0	Modération de contenu
Qwen3Guard-Gen-0.6B	0,6B	Non	Gratuit (bêta)	Apache 2.0	Modération de contenu, version légère

Audio et image

Modèle	Type	Function calling	Prix	Licence
whisper-large-v3	Speech-to-text	N/A (audio)	0,00004083€/second e	Apache 2.0
whisper-large-v3-turbo	Speech-to-text	N/A (audio)	0,00001278€/second e	Apache 2.0
nvr-tts-fr, en-us, de-de, es-es, it-it	Text-to-speech	N/A (audio)	Gratuit	Riva license
stable-diffusion-xl-base-v10	Génération d'image	N/A (image)	Gratuit	OpenRail++

Toutes les valeurs “Oui/Non” de cette partie 3 sont reprises directement du champ “Support” du [catalogue OVHcloud](#) (juillet 2026), source déjà citée en introduction de cette partie.

Recommandations OVH

Meta-Llama-3_3-70B-Instruct	# généraliste solide
Mistral-Small-3.2-24B-Instruct-2506	# généraliste économique, multimodal
gpt-oss-120b	# raisonnement, bon rapport qualité/prix
Qwen3-Coder-30B-A3B-Instruct	# code
bge-m3	# embeddings RAG (cohérent avec RAGaRenn)
whisper-large-v3-turbo	# speech-to-text si besoin, moins cher que
la v3 standard	

OUTILS DE COMPARAISON DES MODÈLES

Arena

Qu’est-ce qu’Arena : plateforme de classement de LLM par vote humain en aveugle, anciennement LMArena / LMSYS Chatbot Arena (créée par des chercheurs de UC Berkeley), rebaptisée “Arena” le 28 janvier 2026 et opérée par Arena Intelligence. Un utilisateur soumet un prompt, deux modèles anonymes répondent, l'utilisateur vote pour la meilleure réponse ; les votes alimentent un système de notation Bradley-Terry (apparenté à l'Elo utilisé aux échecs).

Échelle (au 19/07/2026) : 7 399 550 votes cumulés sur 376 modèles.

Limite méthodologique : un score Elo/Bradley-Terry mesure une préférence perçue par des votants humains, pas une exactitude factuelle mesurée par un test. Le classement a aussi fait l'objet de critiques sur des biais possibles liés à un accès préférentiel de certains fournisseurs au système de test avant publication (cf. papier académique cité ci-dessous).

Sources : - Classement en direct (texte) : [arena.ai/leaderboard/text](#) - Explication de la méthodologie Elo/Bradley-Terry : [BenchLM.ai — Arena Elo Explained](#) - Critique académique de la méthodologie : Singh et al., “The Leaderboard Illusion”, arXiv:2504.20879 — [arxiv.org/pdf/2504.20879](#) - Historique et rebranding LMArena → Arena : [Local AI Master — LMArena Leaderboard 2026](#)